

Bayesova statistika - zapiski s predavanj prof. Smrekarja

Tomaž Poljanšek

študijsko leto 2023/24

Kazalo

| | |
|---|----------|
| Povzetek | 1 |
| 1 Uvod | 1 |
| 1.1 Elementarna Bayesova statistika | 1 |
| 1.2 Proučevani slučajni vektor (vzročni) parametrični model . . . | 2 |
| 1.3 Apriorna in „robna“ porazdelitev | 3 |
| 1.4 Disperzija aposteriornih porazdelitev | 6 |
| Literatura | 8 |
| Dodatki | 9 |

Seznam uporabljenih kratic

| kratica | pomen |
|-------------|--------------------------------|
| s.v. | slučajni vektor |
| B | binomska porazdelitev |
| NEP | neodvisen in enako porazdeljen |
| s.s. | slučajna spremenljivka |
| p.v. | pričakovana vrednost |

Povzetek

Poglavje 1

Uvod

Bayesova statistika je formalni okvir za „osveževanje“ vedenja/znanja o porazdelitvi nekega slučajnega vektorja.

Zgled. 1000, \approx 400Č \rightarrow 600B (apriorno znanje).

Izvedemo (statistični) poskus: izvlečemo 10, dobimo 6 črnih in 4 bele

1.1 Elementarna Bayesova statistika

Privzamemo popoln sistem dogodkov $E_1, E_2 \dots E_m : E_i \cap E_j = \emptyset$ za $i \neq j$ in $E_1 \cup E_2 \cup \dots \cup E_m = \Omega$.

Če imamo še neki dogodek A , velja t.i. zakon o popolni verjetnosti

$P(A) = \sum_{i=1}^m P(A | E_i) \cdot P(E_i)$ (interpretacija: 2-fazni poskus).

V Bayesovem okviru nas zanimajo $P(E_j | A)$ (verjetnost, da se je v „1. fazi“ zgodil E_j , če se je „2. fazi“ zgodil A). Ker je

$$P(E_j | A) = \frac{P(E_j \cap A)}{P(A)}$$

je

$$P(E_j | A) = \frac{P(A | E_j) \cdot P(E_j)}{P(A)} \quad \text{- elementarna pogojna verjetnost}$$

oziroma

$$P(E_j | A) = \frac{P(A | E_j) \cdot P(E_j)}{\sum_{i=1}^m P(A | E_i) \cdot P(E_i)} \quad \text{- elementarna Bayesova formula.}$$

Nadaljujemo zgled. V Bayesovi statistiki predhodno („apriorno“) vedenje formaliziramo kot realizacijo slučajnega eksperimenta. V našem primeru vpeljemo funkcijo, da smo število črnih frnikul θ (- realizacija) dobili kot rezultat slučajne spremenljivke $\Theta \in \{0, 1, 2 \dots 1000\}$.

Informacijo $\theta \approx 400$ zakodiramo kot $E(\Theta) = 400$.

$$\begin{aligned} \text{Privzamemo (kar!) } \Theta &\sim B\left(1000, \frac{4}{10}\right) \\ \Rightarrow P(\Theta = \theta) &= \binom{1000}{\theta} \left(\frac{4}{10}\right)^\theta \left(1 - \frac{4}{10}\right)^{1000-\theta} \\ P(k \text{ črnih od } 10 \text{ izvlečenih} | \Theta = \theta) &= \frac{\binom{\theta}{k} \binom{1000-\theta}{10-k}}{\binom{1000}{k}} \quad (*) \end{aligned}$$

(*) pri omejitvah (k omejimo).

Osvežena porazdelitev - novo vedenje

$$\begin{aligned} P(\Theta = \theta | 6 \text{ črnih od } 10 \text{ izvlečenih}) &= \\ \frac{P(6 \text{ črnih od } 10 \text{ izvlečenih} | \Theta = \theta) \cdot P(B(1000, \frac{4}{10}) = \theta)}{\sum_{i=0}^{1000} P(6 \text{ črnih od } 10 \text{ izvlečenih} | \Theta = i) \cdot P(B(1000, \frac{4}{10}) = i)} &= i \end{aligned}$$

Pravimo ji aposteriorna porazdelitev.

1.2 Proučevani slučajni vektor (vzročni) parametrični model

Naj bo $X = (X_1, X_2 \dots X_n) \in \mathbb{R}^n$ preučevani slučajni vektor. Pogosto so neodvisni in enako porazdeljeni (NEP) realizacija danega slučajnega eksperimenta. S pomočjo statistike lahko „ocenjujemo“ porazdelitev slučajnega vektorja X . Zanj privzamemo, da pripada nekemu modelu, t.j. neki množici dopustnih rešitev. Privzamemo, da je ta množica parametrizirana s parametričnim prostorom $\Theta \subset \mathbb{R}^r$. Tu si mislimo, da parameter $\theta \in \Theta$ dobimo kot realizacijo slučajnega vektorja (s.v.) Θ z vrednostmi v Θ (večinoma $r \geq 2$).

Porazelitvi s.v. X_i pogojno na $\Theta = \theta$ pravimo vzorčna porazdelitev. Privzeli bomo, da imamo gostote $f(x | \theta)$ ali verjetnostne funkcije

$$P(X = x | \theta) = f(x | \theta),$$

torej da velja

$$P(X \in B | \Theta = \theta) = \int_B f(x | \theta) d\nu(x)$$

(v Lebesgueovi meri) ali

$$P(X \in B | \Theta = \theta) = \sum_{x \in B} f(x | \theta).$$

Modelu pogojnih porazdelitev $(X | \Theta = \theta)$ pravimo vrščni model.

1.3 Apriorna in „robna“ porazdelitev

Porazdelitvi fiktivnega slučajnega vektorja Θ pravimo apriorna porazdelitev, brezpogojni (robni) porazdelitveni slučajnega vektorja X pa pravimo „robna“ porazdelitev

(*) v resnici sta obe porazdelitvi robni porazdelitvi družne porazdelitve vektorja (X, Θ) z vrednostmi v \mathbb{R}^{n+r} .

Zgled. Ocenjujemo Bernoullijevo porazdelitev. Predhodno vedenje je podano z apriorno prazdelitvijo na $(0,1)$; mislimo si, da je p realizacija slučajne spremenljivke (s.s.) Π z vrednostmi v $(0,1)$. Možnosti:

- nimamo apriornega mnenja o (dejanskem) p : tedaj bi (morda) vzeli zvezno porazdelitev z gostoto enakomerna porazdelitve,
- smo „zelo“ prepričani, da je (dejanski) $p \approx \frac{1}{2}$.

Recimo, da je $f(p)$ gostota apriorne porazdelitve. Tedaj so apriorne verjetnosti

$$P(\Pi \in (a,b)) = \int_a^b f(p) dp$$

in apriorna pričakovana vrednost

$$E(\Pi) = \int_0^1 p f(p) dp.$$

Pripomnimo, da pri $\Pi \sim U(0,1)$ dobimo $E(U(0,1)) = \frac{1}{2}$.

Privzemimo, da smo „vzorčili“ p , potem pa „neodvisno“ n -krat vržemo p -kovanec ($P(\text{cifra} = p)$), gre za slučajne spremenljivke $X_1, X_2 \dots X_n$, za katere je $(X_i \mid \Pi = p) \sim \text{Bernoulli}(p)$ in so $X_1 \dots X_n$ neodvisne pogojno na p . To ne pomeni, da do $X_1 \dots X_n$ brezpogojno neodvisne.

Za $i \neq j$ je

$$\begin{aligned} P(X_i = 1 \wedge X_j = 1) &= \int_0^1 P(X_i = 1 \wedge X_j = 1 \mid \Pi = p) f(p) dp = \\ &\stackrel{\text{pogojno neodvisne}}{=} \int_0^1 P(X_i = 1 \mid \Pi = p) P(X_j = 1 \mid \Pi = p) f(p) dp = \\ &= \int_0^1 p^2 f(p) dp = \\ &= E(\Pi^2). \end{aligned}$$

Ker je $P(X_i = 1) = \int_0^1 P(X_i = 1 \mid p) f(p) dp = \int_0^1 p f(p) dp = E(\Pi)$, je

$$\text{Cov}(X_i, X_j) = E(\Pi^2) - E(\Pi)^2 = D(\Pi)$$

za $i \neq j$, torej so X_i brezpogojno neodvisne $\iff \Pi = \text{konstantna}$ (slučajna spremenljivka).

Tvorimo $X = X_1 + \dots + X_n \in \{0, 1 \dots n\}$. To je „preučevana“ slučajna spremenljivka. Velja $(X \mid \Pi = p) \sim B(n, p)$. To je vzorčna porazdelitev; vzročni model je parametriziran s prostorom parametrov $(0,1) = \Theta$. Robna porazdelitev je podana z verjetnostmi

$$\begin{aligned} P(X = k) &= \int_0^1 P(X = k \mid p) f(p) dp = \\ &= \int_0^1 \binom{n}{k} p^k (1-p)^{n-k} f(p) dp. \end{aligned}$$

Recimo, da „opazimo“ $X = k$. Aposteriorna porazdelitev (osveženo vedenje o p) je sestavljeno iz verjetnosti

$$\begin{aligned} P(X \in (a,b) \mid X = k) &= \frac{P(X = k \wedge \Pi \in (a,b))}{P(X = k)} = \\ &= \frac{\int_0^1 P(X = k \wedge \Pi \in (a,b) \mid \Pi = p) f(p) dp}{P(X = k)} = \\ &= \int_a^b \frac{P(X = k \mid \Pi = p)}{P(X = k)} f(p) dp. \end{aligned}$$

Opazimo, da ima aposteriorna porazdelitev $(\Pi \mid X = k)$ gostoto

$$f_{(\pi|X)}(p \mid k) = \frac{P(X = k \mid p)f(p)}{P(X = k)}.$$

Zgornji formuli pravimo Bayesova formula.

Za številsko oceno za p bi lahko vzeli pričakovano vrednost aposteriorne porazdelitve

$$\hat{p} = E(\Pi \mid X = k) = \int_0^1 p \cdot f(p \mid k) dp.$$

Pravimo ji aposteriorna pričakovana vrednost.

Posebej priročna družina apriornih porazdelitev (za binomske vzorčne porazdelitve) je t.i. $Beta = \{Beta(a, b) \mid a, b \in (0, \infty)\}$

$$f_{Beta(a,b)}(p) = \frac{1}{B(a,b)} p^{a-1} (1-p)^{b-1} 1_{(0,1)}(p)$$

(tu je $B(a, b) = \int_0^1 p^{a-1} (1-p)^{b-1} dp$).

$$E(Beta(a, b)) = \frac{a}{a+b}$$

$$D(Beta(a, b)) = \frac{ab}{(a+b)^2(a+b+1)}.$$

$D(Beta(a, b))$ predstavlja „težo“ apriornega prepričanja; večji - manj sigurni smo.

$$E(Beta(a, b)) = 0.7.$$

Aposteriorna porazdelitev ima gostoto (če je $f(p) = f_{Beta(a,b)}(p)$)

$$\begin{aligned} f(p \mid k) &= \frac{\binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{1}{B(a,b)} p^{a-1} (1-p)^{b-1}}{P(X = k)} = \\ &= \text{konst.} \cdot p^{a+k-1} (1-p)^{b+n-k-1}. \end{aligned}$$

Vidimo, da je $(\Pi \mid X = k) \sim Beta(a+k, b+n-k)$.

Aposteriorna pričakovana vrednost (p.v.) je

$$\begin{aligned} \frac{a+k}{a+b+n} &= \frac{(a+b) \frac{a}{a+b} + n \frac{k}{n}}{a+b+n} = \\ &= \frac{a+b}{a+b+n} \cdot \frac{a}{a+b} + \frac{n}{a+b+n} \cdot \frac{k}{n}. \end{aligned}$$

Tukaj je

- $\frac{a}{a+b}$ apriorna ocena,
- $\frac{k}{n}$ vzorčna ocena in
- $\frac{a+b}{a+b+n}$ in $\frac{n}{a+b+n}$ faktorja pri konveksni kombinaciji obeh ocen.

Vzorec velik \rightarrow prevlada mnenje vzorca.

1.4 Disperzija aposteriornih porazdelitev

Gre pravzaprav za disperzijo pogojnih porazdelitev. Naj bosta $X : \Omega \rightarrow \mathbb{R}^m$ in $Y : \Omega \rightarrow \mathbb{R}^n$ in naj ima (X, Y) gostoto $f_{(X,Y)}$ glede na $\mu \times \nu$. Sledita gostoti $f_X(x) = \int f_{(X,Y)}(x, y) d\nu(y)$ za X glede na μ in $f_Y(y) = \int f_{(X,Y)}(x, y) d\mu(x)$ za Y glede na ν . Dalje definiramo pogojni porazdelitvi ($Y \mid X = x$) in ($X \mid Y = y$) preko gostot

$$f_{(Y|X)}(y \mid x) = \frac{f_{(X,Y)}(x, y)}{f_X(x)}$$

glede na ν : gostota v $X \rightarrow \mu$ in simetrično za $f_{(X|Y)}(x \mid y)$.

$P(Y \in B \mid X = x) = \int_B f_{(Y|X)}(y \mid x) d\nu(y)$ - porazdelitev, opremljena z gostoto.

Definicija 1.4.1.

$$E(Y \mid X = x) = \int y f_{(Y|X)}(y \mid x) d\nu(y).$$

y lahko zamenjamo s $h(y)$.

Pišemo $E(Y \mid X = x) = u(X)$ - h je identiteta.

Definicija 1.4.2.

$$E(Y \mid X) = u(X) : \Omega \rightarrow \mathbb{R}^n.$$

Slučajni vektor \rightarrow pogojna pričakovana vrednost,

oz.

$$E(Y \mid X)(\omega) = u(X(\omega)) = E(Y \mid X = X(\omega)).$$

$E(Y \mid X)(\omega)$: funkcija na X , kompozitum.

$X(\omega)$: vrednost.

Definicija 1.4.3. Pogojno varianco slučajnega vektorja Y , pogojno na $X = x$ definiramo kot varianco pogojne porazdelitve $(Y \mid X = x)$, t.j.

$$E((Y - u(X))(Y - u(X))^T \mid X = x) =: \text{Var}(Y \mid X = x).$$

Ker je E aditivna, velja

$$E((Y - u(X))(Y - u(X))^T \mid X = x) = E(YY^T \mid X = x) - u(X)u(X)^T =: v(X).$$

$v(X)$ je $n \times n$ matrika.

Definicija 1.4.4. Pogojna varianca slučajnega vektorja Y pogojno na slučajni vektor X je

$$\text{Var}(Y \mid X) = v(X).$$

Literatura

Dodatki